TP n°2 - Classification: régression logistique et SVM

Salim Nadir et Guillaume Ostrom

Application I : Régression logistique

Nous constatons que le fichier SaHeart.info décrit les différentes variables présentes dans le fichier SaHeart.txt, où la dernière colonne (chd) est la variable cible.

1. Les données

Procédons au chargement du fichier SaHeart.txt:

```
setwd(getwd())
heartData = read.table('SaHeart.txt',header=TRUE,sep=",")
summary(heartData)
```

```
##
                                        tobacco
                                                             ldl
      row.names
                         sbp
          : 1.0
##
                           :101.0
                                          : 0.0000
                                                               : 0.980
   Min.
                    Min.
                                     Min.
                                                       Min.
   1st Qu.:116.2
                    1st Qu.:124.0
                                     1st Qu.: 0.0525
                                                       1st Qu.: 3.283
##
  Median :231.5
                    Median :134.0
                                     Median : 2.0000
                                                       Median : 4.340
##
   Mean
           :231.9
                    Mean
                           :138.3
                                     Mean
                                            : 3.6356
                                                               : 4.740
                                                       Mean
##
    3rd Qu.:347.8
                    3rd Qu.:148.0
                                     3rd Qu.: 5.5000
                                                       3rd Qu.: 5.790
           :463.0
                    Max.
                           :218.0
                                            :31.2000
##
   Max.
                                     Max.
                                                       Max.
                                                               :15.330
##
      adiposity
                       famhist
                                       typea
                                                     obesity
##
   Min.
           : 6.74
                    Absent :270
                                  Min.
                                          :13.0
                                                  Min.
                                                          :14.70
##
   1st Qu.:19.77
                    Present:192
                                   1st Qu.:47.0
                                                  1st Qu.:22.98
   Median :26.11
                                   Median:53.0
                                                  Median :25.80
           :25.41
                                          :53.1
                                                          :26.04
##
   Mean
                                   Mean
                                                  Mean
##
    3rd Qu.:31.23
                                   3rd Qu.:60.0
                                                  3rd Qu.:28.50
##
   Max.
           :42.49
                                   Max.
                                          :78.0
                                                  Max.
                                                         :46.58
##
       alcohol
                                           chd
                           age
##
    Min.
          : 0.00
                     Min.
                            :15.00
                                      Min.
                                             :0.0000
##
   1st Qu.: 0.51
                     1st Qu.:31.00
                                      1st Qu.:0.0000
##
  Median: 7.51
                     Median :45.00
                                      Median :0.0000
##
  Mean
           : 17.04
                     Mean
                            :42.82
                                      Mean
                                             :0.3463
    3rd Qu.: 23.89
                     3rd Qu.:55.00
                                      3rd Qu.:1.0000
    Max.
           :147.19
                     Max.
                            :64.00
                                      Max.
                                             :1.0000
```

attributes(heartData)\$names

```
## [1] "row.names" "sbp" "tobacco" "ldl" "adiposity"
## [6] "famhist" "typea" "obesity" "alcohol" "age"
## [11] "chd"
```

Voici les correspondances de chaque variable:


⁻ sbp : la pression systolique,

- tobacco : la quantité en kilogrammes de tabac ingérée,
- ldl : lipoprotéine de basse densité,
- famhist : antécédent d'attaque cardiaque,
- typea: type-A,
- obesity : indice de masse corporelle,
- alcohol : consommation d'alcool par semaine en litre,
- age : âge de l'individu,
- chd : attaque cardiaque observée chez l'individu.

2. Scatterplot

Affichons le scatterplot du jeu de données:

pairs(heartData, pch=25, bg=c("firebrick","deepskyblue3"))[unclass(factor(heartData[, "chd"]))]



NULL

3. Régression logistique

```
regLogistic = glm("chd~.", family=gaussian, heartData)
summary(regLogistic)
```

```
##
## Call:
## glm(formula = "chd~.", family = gaussian, data = heartData)
##
## Deviance Residuals:
                    Median
##
      Min
               1Q
                                 3Q
                                        Max
## -0.7635 -0.3319 -0.1058
                             0.3742
                                      1.0376
##
## Coefficients:
##
                  Estimate Std. Error t value Pr(>|t|)
## (Intercept)
                -0.0001633 0.0001524 -1.071 0.284568
## row.names
                 0.0015503 0.0010762
                                       1.441 0.150411
## sbp
                 0.0162667  0.0048692  3.341  0.000905 ***
## tobacco
                 0.0324112 0.0106970
                                       3.030 0.002587 **
## ldl
## adiposity
                 0.0027633 0.0047882
                                       0.577 0.564147
## famhistPresent 0.1750802 0.0412966
                                       4.240 2.72e-05 ***
## typea
                0.0057758 0.0020565
                                       2.809 0.005193 **
## obesity
                -0.0117786 0.0070532 -1.670 0.095618 .
## alcohol
                -0.0001667 0.0008308 -0.201 0.841034
## age
                 0.0066377 0.0019958 3.326 0.000954 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for gaussian family taken to be 0.1767215)
##
##
      Null deviance: 104.589 on 461 degrees of freedom
## Residual deviance: 79.701 on 451 degrees of freedom
## AIC: 523.24
##
## Number of Fisher Scoring iterations: 2
```

On constate que les p-values des variables tabacco, famhist et age sont faibles donc fortement significatives. Nous observons que les variables tabacco, famhist et age sont les variables les plus explicatives.

4. Comparaisons

On calcule la matrice de confusion.

```
confMatrix[2,2] = confMatrix[2,2] + 1
      }else{
         confMatrix[2,1] = confMatrix[2,1] + 1
      }
    }else{
      predictHeartAttackBoolean[i] = 0
      if(heartData$chd[i]==1){
        confMatrix[1,2] = confMatrix[1,2] + 1
      }else{
         confMatrix[1,1] = confMatrix[1,1] + 1
      }
    }
  }
probaFaslePositive = confMatrix[2,1]/(confMatrix[1,1] + confMatrix[2,1])
probaFasleNegative = confMatrix[1,2]/(confMatrix[1,2] + confMatrix[2,2])
  return (list ("Matrice de confusion"=confMatrix, "Probabilité de risque de faux positif "=probaFasleP
}
confusionMatrix = getConfusionMatrix(predictHeartAttack, heartData)
print(confusionMatrix)
## $`Matrice de confusion`
          chd=0 chd=1
## pred=0
            262
                   82
             40
## pred=1
## $`Probabilité de risque de faux positif `
## [1] 0.1324503
##
## $`Probabilité de risque de faux négatif `
## [1] 0.4875
#NB: Methode de calcul plus directe de la matrice de confusion:
matrixConf2 = table(regLogistic$fitted.values>0.5,heartData[,"chd"])
print(matrixConf2)
##
##
             0
##
     FALSE 262 78
```

On constate 13 % de risque de faux positif et 49 % de risque de faux négatif.

5. Validation croisée

40 82

TRUE

##

Nous définisons 75% de nos données comme étant des données d'apprentissage, les 25% restant seront destinées à tester notre modèle.

```
#On prend aléatoirement sans remise les données d'apprentissage (75%) et les données de test (25%).
dt = sort(sample(nrow(heartData), 0.75*nrow(heartData)))
trainData75<-heartData[dt,]</pre>
testData25<-heartData[-dt,]
#Regression logistic sur les données d'apprentissage
regLogistic75 = glm("chd~.", family=gaussian, trainData75)
summary(regLogistic75)
##
## Call:
## glm(formula = "chd~.", family = gaussian, data = trainData75)
## Deviance Residuals:
       Min 10
                       Median
                                    3Q
                                             Max
## -0.89800 -0.33098 -0.07637 0.36471
                                         1.04986
## Coefficients:
##
                  Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.5421556 0.2319968 -2.337 0.020033 *
## row.names
               -0.0001279 0.0001748 -0.732 0.464704
## sbp
                 0.0013768 0.0012285
                                      1.121 0.263215
## tobacco
                ## ldl
                0.0389489 0.0124599 3.126 0.001927 **
## adiposity
                0.0004083 0.0054316 0.075 0.940126
## famhistPresent 0.1450772 0.0477514 3.038 0.002567 **
## typea
                0.0066049 0.0023370 2.826 0.004992 **
## obesity
               -0.0113160 0.0076823 -1.473 0.141692
## alcohol
                0.0003982 0.0009662 0.412 0.680532
## age
                 0.0088431 0.0024076 3.673 0.000279 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## (Dispersion parameter for gaussian family taken to be 0.1759232)
##
##
      Null deviance: 80.116 on 345 degrees of freedom
## Residual deviance: 58.934 on 335 degrees of freedom
## AIC: 393.48
## Number of Fisher Scoring iterations: 2
#Prediction avec les données de test
predictHeartAttack75_25 = predict(regLogistic75, testData25)
#Matrice de confusion du modèle
confusionMatrix75_25 = getConfusionMatrix(predictHeartAttack75_25, testData25)
print(confusionMatrix75_25)
## $`Matrice de confusion`
         chd=0 chd=1
## pred=0
            64
                 13
## pred=1
            18
                  21
```

##

```
## $`Probabilité de risque de faux positif `
## [1] 0.2195122
##
## $`Probabilité de risque de faux négatif `
## [1] 0.3823529
```

Pour ce modèle de *cross validation* nous obtenons un risque de faux positif de 13.2% et un risque de faux négatif de 50.0%. Notons que ces résultats sont proches d'une regression logistique sur l'ensemble des données, on peut en déduire la bonne significativité du modèle.

Répétons plusieurs fois cette procédure.

```
checkCrossValidation = function(heartData, iterations) {
 confMatrix75_25 = c()
 error = c()
   for (i in 1:iterations) {
      dt = sort(sample(nrow(heartData), 0.75*nrow(heartData)))
      data75<-heartData[dt,]
      data25<-heartData[-dt,]
      #Regression logistic sur les donn?es d'apprentissage
     regLog75 = glm("chd~.", family=gaussian, data75)
      #Prediction avec les donn?es de test
     predict75_25 = predict(regLog75, data25)
      #Matrice de confusion du mod?le
      confMat = getConfusionMatrix(predict75_25, data25)
      confMatrix75_25[i] = confMat[1]
      error[i] = (as.numeric(confMat[[1]][1,2])+as.numeric(confMat[[1]][2,1]) )/ (as.numeric(confMat[[
   }
return (list("Erreur minimum"=error[which.min(error)], "Erreur maximum"=error[which.max(error)], "Erreu
print(checkCrossValidation(heartData, 250))
## $`Erreur minimum`
## [1] 0.1724138
##
## $`Erreur maximum`
## [1] 0.362069
```

On remarque que l'erreur minimum est à 17% et que l'erreur maximum est élevée à 38% avec une moyenne d'erreur à 27%, ce qui est acceptable.

Tester son modéle sur les données d'entrainement conduirait à sous-estimer l'erreur, et donc a un biais. L'intérêt de cette approche est de tester la significativité d'un modèle entrainé sur 75% des données et de le tester sur les 25% données restantes.

On peut en déduire que notre modèle est plutôt pertinant.

\$`Erreur moyenne` ## [1] 0.2706552

6. Sélection des variables

```
# Backward
regBackward = step(regLogistic75, direction='backward', k=log(nrow(heartData)))
## Start: AIC=438.97
## chd ~ row.names + sbp + tobacco + ldl + adiposity + famhist +
      typea + obesity + alcohol + age
##
##
              Df Deviance
## - adiposity 1
                  58.935 432.84
## - alcohol
                  58.964 433.01
              1
## - row.names 1
                  59.029 433.39
## - sbp
                  59.155 434.13
         1
## - obesity
              1 59.316 435.07
## <none>
                  58.934 438.97
## - tobacco
            1 60.163 439.97
## - typea
             1 60.340 440.99
             1 60.558 442.24
## - famhist
## - ldl
              1
                  60.653 442.78
## - age
              1 61.308 446.50
##
## Step: AIC=432.84
## chd ~ row.names + sbp + tobacco + ldl + famhist + typea + obesity +
##
      alcohol + age
##
##
             Df Deviance
                            AIC
## - alcohol
            1 58.965 426.88
## - row.names 1 59.029 427.25
## - sbp
             1 59.160 428.02
## - obesity 1 59.585 430.50
                  58.935 432.84
## <none>
## - tobacco
            1 60.163 433.84
## - typea
             1 60.340 434.85
              1
## - famhist
                  60.558 436.11
## - ldl
              1
                  60.756 437.23
## - age
              1 62.288 445.85
##
## Step: AIC=426.88
## chd ~ row.names + sbp + tobacco + ldl + famhist + typea + obesity +
##
      age
##
             Df Deviance
##
                            AIC
                  59.051 421.25
## - row.names 1
## - sbp
                  59.207 422.16
              1
## - obesity
                  59.604 424.48
                  58.965 426.88
## <none>
## - tobacco
             1 60.262 428.27
## - typea
             1 60.402 429.08
## - famhist
              1
                  60.616 430.30
## - ldl
                  60.756 431.10
             1
## - age
             1 62.339 440.00
##
```

```
## Step: AIC=421.25
## chd ~ sbp + tobacco + ldl + famhist + typea + obesity + age
##
          Df Deviance
                          AIC
## - sbp
           1 59.246 416.25
## - obesity 1 59.678 418.77
                59.051 421.25
## <none>
## - tobacco 1 60.371 422.76
## - typea 1 60.642 424.31
## - famhist 1 60.672 424.48
## - ldl 1 60.929 425.95
           1 62.539 434.97
## - age
##
## Step: AIC=416.25
## chd ~ tobacco + ldl + famhist + typea + obesity + age
##
##
            Df Deviance
                          AIC
## - obesity 1 59.807 413.38
               59.246 416.25
## <none>
## - tobacco 1 60.570 417.77
## - typea 1 60.871 419.48
## - famhist 1 60.877 419.51
## - ldl 1 61.171 421.18
           1 63.534 434.29
## - age
##
## Step: AIC=413.38
## chd ~ tobacco + ldl + famhist + typea + age
           Df Deviance
##
                          AIC
         59.807 413.38
## <none>
## - tobacco 1 61.106 414.68
## - typea 1 61.243 415.46
## - ldl
           1 61.337 415.99
## - famhist 1 61.393 416.30
            1 63.676 428.93
## - age
formula(regBackward)
## chd ~ tobacco + ldl + famhist + typea + age
## <environment: 0x00000001787b1c8>
#NB Forward
regForward = step(regLogistic75, direction='forward', k=log(nrow(heartData)))
## Start: AIC=438.97
## chd ~ row.names + sbp + tobacco + ldl + adiposity + famhist +
      typea + obesity + alcohol + age
formula(regForward)
## chd ~ row.names + sbp + tobacco + ldl + adiposity + famhist +
      typea + obesity + alcohol + age
## <environment: 0x00000001787b1c8>
```

```
regBoth = step(regLogistic75, direction='both', k=log(nrow(heartData)))
## Start: AIC=438.97
## chd ~ row.names + sbp + tobacco + ldl + adiposity + famhist +
      typea + obesity + alcohol + age
##
##
              Df Deviance
                             AIC
## - adiposity 1
                   58.935 432.84
## - alcohol
                   58.964 433.01
               1
## - row.names 1
                   59.029 433.39
## - sbp
              1 59.155 434.13
               1 59.316 435.07
## - obesity
## <none>
                   58.934 438.97
## - tobacco
               1
                   60.163 439.97
## - typea
                   60.340 440.99
               1
## - famhist
                   60.558 442.24
               1
## - ldl
               1
                   60.653 442.78
## - age
                   61.308 446.50
##
## Step: AIC=432.84
## chd ~ row.names + sbp + tobacco + ldl + famhist + typea + obesity +
      alcohol + age
##
              Df Deviance
## - alcohol
              1 58.965 426.88
                   59.029 427.25
## - row.names 1
## - sbp
                 59.160 428.02
         1
## - obesity
               1 59.585 430.50
## <none>
                   58.935 432.84
## - tobacco
               1
                   60.163 433.84
                   60.340 434.85
## - typea
               1
## - famhist
                   60.558 436.11
               1
                   60.756 437.23
## - ldl
               1
                   58.934 438.97
## + adiposity 1
## - age
                   62.288 445.85
##
## Step: AIC=426.88
## chd ~ row.names + sbp + tobacco + ldl + famhist + typea + obesity +
##
              Df Deviance
                             AIC
## - row.names 1 59.051 421.25
                   59.207 422.16
## - sbp
              1
## - obesity
                   59.604 424.48
               1
## <none>
                   58.965 426.88
## - tobacco
                   60.262 428.27
## - typea
               1
                   60.402 429.08
                   60.616 430.30
## - famhist
               1
## - ldl
                   60.756 431.10
               1
               1 58.935 432.84
## + alcohol
## + adiposity 1 58.964 433.01
## - age
                   62.339 440.00
```

```
##
## Step: AIC=421.25
## chd ~ sbp + tobacco + ldl + famhist + typea + obesity + age
             Df Deviance
                        AIC
## - sbp
             1 59.246 416.25
## - obesity
            1 59.678 418.77
                 59.051 421.25
## <none>
## - tobacco
            1 60.371 422.76
## - typea
            1 60.642 424.31
## - famhist 1 60.672 424.48
            1 60.929 425.95
## - ldl
## + row.names 1 58.965 426.88
## + alcohol 1 59.029 427.25
## + adiposity 1 59.051 427.38
## - age
              1
                 62.539 434.97
##
## Step: AIC=416.25
## chd ~ tobacco + ldl + famhist + typea + obesity + age
##
            Df Deviance
                          AIC
## - obesity
            1 59.807 413.38
                 59.246 416.25
## <none>
            1 60.570 417.77
## - tobacco
            1 60.871 419.48
## - typea
## - famhist 1 60.877 419.51
## - ldl
             1 61.171 421.18
## + sbp
            1 59.051 421.25
## + alcohol 1 59.207 422.16
## + row.names 1 59.207 422.16
## + adiposity 1 59.243 422.37
## - age
              1
                 63.534 434.29
##
## Step: AIC=413.38
## chd ~ tobacco + ldl + famhist + typea + age
##
             Df Deviance
                          AIC
## <none>
                 59.807 413.38
            1 61.106 414.68
## - tobacco
## - typea 1 61.243 415.46
## - ldl
            1 61.337 415.99
## + obesity 1 59.246 416.25
## - famhist 1 61.393 416.30
## + adiposity 1 59.589 418.25
## + sbp
              1 59.678 418.77
## + row.names 1 59.770 419.30
                 59.782 419.37
## + alcohol
            1
## - age
              1
                 63.676 428.93
formula(regBoth)
## chd ~ tobacco + ldl + famhist + typea + age
```

<environment: 0x00000001787b1c8>

```
Une régression en direction backward nous sélectionne les 4 variables suivantes:
- famhist
- age
- tabacco
- ldl
heartDataBackward = heartData[c(3, 4, 6, 10, 11)]
print(attributes(heartDataBackward)$names)
## [1] "tobacco" "ldl"
                            "famhist" "age"
                                                 "chd"
dtBackward = sort(sample(nrow(heartDataBackward)), 0.75*nrow(heartDataBackward)))
dataBackward75<-heartDataBackward[dtBackward,]</pre>
dataBackward25<-heartDataBackward[-dtBackward,]
#Regression logistic sur les donn?es d'apprentissage
regLog75_Backward = glm("chd~.", family=gaussian, dataBackward75)
#Prediction avec les donn?es de test
predict75_25_Backward = predict(regLog75_Backward, dataBackward25)
#Matrice de confusion du mod?le
confMatBackward = getConfusionMatrix(predict75_25_Backward, dataBackward25)
print(confMatBackward)
## $`Matrice de confusion`
##
          chd=0 chd=1
                    20
## pred=0
             66
## pred=1
             10
                    20
## $`Probabilité de risque de faux positif `
## [1] 0.1315789
##
## $`Probabilité de risque de faux négatif `
## [1] 0.5
print(checkCrossValidation(heartDataBackward, 150))
## $`Erreur minimum`
## [1] 0.1724138
##
## $`Erreur maximum`
## [1] 0.3706897
## $`Erreur moyenne`
```

Nous observons qu'avec un step **backward** l'erreur minimum est à 18% et l'erreur maximum à 38% et la même erreur moyenne est à 27%.

[1] 0.2777586

Nous remarquons qu'il n'y a pas d'amélioration de l'erreur par rapport au modèle complet, ce qui donne un avantage à ce modèle car il nécessite moins de données pour le même résultat.


7. Courbe ROC

```
Comparons à l'aide des courbes ROC ces 3 modèles de régression logistique: 1)Modèle complet 2)Modèle avec les variables sélectionnées 3)Modèle avec la variable la plus significative
```

plotRoc(predictHeartAttack75_25,testData25,"cyan4", TRUE)


Import de la bibliothéque ROC

```
#install.packages("ROCR")
library(ROCR)
## Loading required package: gplots
## Attaching package: 'gplots'
## The following object is masked from 'package:stats':
##
##
       lowess
library(gplots)
plotRoc = function(predictTrain, dataTrainTest, color, added){
rocPred = prediction(predictTrain, dataTrainTest["chd"])
rocPerf = performance(rocPred, measure = "tpr", x.measure = "fpr")
plot(rocPerf, add= added, col=color)
}
#Mod?le Complet Train
predictHeartAttack75_75 = predict(regLogistic75, trainData75)
plotRoc(predictHeartAttack75_75,trainData75,"cyan2", FALSE)
#Mod?le Complet Test
```



```
#Mod?le Backward Train
predict75_75_Backward = predict(regLog75_Backward, dataBackward75)
plotRoc(predict75_75_Backward,dataBackward75, "darkgoldenrod1",FALSE)


#Mod?le Backward Test
plotRoc(predict75_25_Backward,dataBackward25,"darkgoldenrod4",TRUE)
```



```
#Mod?le mono variable
dtmono = sort(sample(nrow(heartData), 0.75*nrow(heartData)))
dataMono75<-heartData[dtmono,]
dataMono25<-heartData[-dtmono,]

#Mod?le mono Train
regLogisticMono = glm("chd~ldl", family=gaussian, heartData)
predict75_75_mono = predict(regLogisticMono, dataMono75)
plotRoc(predict75_75_mono,dataMono75, "red",FALSE)

#Mod?le mono variable
predict75_25_mono = predict(regLogisticMono, dataMono25)
plotRoc(predict75_25_mono,dataMono25, "blue",TRUE)</pre>
```



En conclusion, le modèle complet n°1 donne certes des résultats comparable à celui du n°2, mais comporte plus de variables et donc de données pour y arriver. Aussi, le modèle n°3 qui se résume à une variable explicative n'est pas suffisament pertinant.

Donc les courbes ROC montrent que le $\mathbf{mod\`ele}\ \mathbf{n}^{\circ}\mathbf{2}$ issu d'une sélection des 4 meilleurs variables et le modèle le plus adapté.

Application II : Classification par SVM

Analyse préliminaire

1. Etude rapide

Toutes les informations liées aux données spam sont dans le fichier $\mathbf{spaminfo.txt}$

2. Chargement des données

Nous procédons au chargement des données spam.

```
spamData = read.table("spam.txt", header=TRUE, sep=';')
```

3. Observations

summary(spamData)

```
##
                            A.2
                                              A.3
                                                                 A.4
         A . 1
##
    Min.
            :0.0000
                      Min.
                              : 0.000
                                         Min.
                                                 :0.0000
                                                           Min.
                                                                   : 0.00000
                                         1st Qu.:0.0000
    1st Qu.:0.0000
                      1st Qu.: 0.000
                                                           1st Qu.: 0.00000
##
    Median :0.0000
                      Median : 0.000
                                         Median : 0.0000
                                                           Median: 0.00000
##
    Mean
            :0.1046
                      Mean
                              : 0.213
                                         Mean
                                                :0.2807
                                                           Mean
                                                                   : 0.06542
##
    3rd Qu.:0.0000
                      3rd Qu.: 0.000
                                         3rd Qu.:0.4200
                                                           3rd Qu.: 0.00000
                                                                   :42.81000
##
    Max.
            :4.5400
                              :14.280
                                                 :5.1000
                      Max.
                                         Max.
                                                           Max.
##
         A.5
                             A.6
                                               A.7
                                                                  A.8
                               :0.0000
##
    Min.
            : 0.0000
                       Min.
                                          Min.
                                                  :0.0000
                                                            Min.
                                                                    : 0.0000
    1st Qu.: 0.0000
                        1st Qu.:0.0000
                                          1st Qu.:0.0000
                                                             1st Qu.: 0.0000
    Median : 0.0000
                        Median :0.0000
                                          Median :0.0000
##
                                                            Median: 0.0000
          : 0.3122
##
    Mean
                       Mean
                               :0.0959
                                          Mean
                                                  :0.1142
                                                            Mean
                                                                   : 0.1053
                        3rd Qu.:0.0000
##
    3rd Qu.: 0.3800
                                          3rd Qu.:0.0000
                                                             3rd Qu.: 0.0000
##
    Max.
            :10.0000
                       Max.
                               :5.8800
                                          Max.
                                                  :7.2700
                                                            Max.
                                                                    :11.1100
         A.9
                                                A.11
                                                                    A.12
##
                             A.10
                       Min.
##
    Min.
            :0.00000
                               : 0.0000
                                           Min.
                                                   :0.00000
                                                              Min.
                                                                      :0.0000
##
    1st Qu.:0.00000
                        1st Qu.: 0.0000
                                           1st Qu.:0.00000
                                                               1st Qu.:0.0000
    Median :0.00000
                        Median : 0.0000
                                           Median :0.00000
                                                               Median :0.1000
##
##
    Mean
            :0.09007
                        Mean
                               : 0.2394
                                           Mean
                                                   :0.05982
                                                               Mean
                                                                      :0.5417
##
    3rd Qu.:0.00000
                        3rd Qu.: 0.1600
                                           3rd Qu.:0.00000
                                                               3rd Qu.:0.8000
##
    Max.
            :5.26000
                        Max.
                               :18.1800
                                           Max.
                                                   :2.61000
                                                               Max.
                                                                      :9.6700
##
         A.13
                             A.14
                                                  A.15
                                                                    A.16
##
    Min.
            :0.00000
                               : 0.00000
                                                    :0.0000
                                                                      : 0.0000
                       Min.
                                            Min.
                                                               Min.
                        1st Qu.: 0.00000
##
    1st Qu.:0.00000
                                            1st Qu.:0.0000
                                                               1st Qu.: 0.0000
    Median :0.00000
                        Median: 0.00000
                                            Median :0.0000
                                                               Median: 0.0000
                               : 0.05863
##
    Mean
            :0.09393
                        Mean
                                            Mean
                                                    :0.0492
                                                               Mean
                                                                      : 0.2488
                        3rd Qu.: 0.00000
                                                               3rd Qu.: 0.1000
##
    3rd Qu.:0.00000
                                            3rd Qu.:0.0000
##
    Max.
            :5.55000
                               :10.00000
                                                    :4.4100
                                                               Max.
                                                                      :20.0000
                        Max.
                                            Max.
         A.17
                            A.18
                                              A.19
                                                                 A.20
##
##
    Min.
            :0.0000
                      Min.
                              :0.0000
                                         Min.
                                                : 0.000
                                                           Min.
                                                                   : 0.00000
##
    1st Qu.:0.0000
                      1st Qu.:0.0000
                                         1st Qu.: 0.000
                                                           1st Qu.: 0.00000
                      Median :0.0000
##
    Median :0.0000
                                         Median : 1.310
                                                           Median: 0.00000
##
    Mean
           :0.1426
                      Mean
                              :0.1847
                                         Mean
                                                : 1.662
                                                           Mean
                                                                   : 0.08558
##
    3rd Qu.:0.0000
                      3rd Qu.:0.0000
                                         3rd Qu.: 2.640
                                                           3rd Qu.: 0.00000
##
    Max.
            :7.1400
                              :9.0900
                                                :18.750
                                                                   :18.18000
                      Max.
                                         Max.
                                                           Max.
##
         A.21
                             A.22
                                                A.23
                                                                   A.24
##
           : 0.0000
                               : 0.0000
                                                                     : 0.00000
    Min.
                       Min.
                                           Min.
                                                   :0.0000
                                                             Min.
                        1st Qu.: 0.0000
##
    1st Qu.: 0.0000
                                           1st Qu.:0.0000
                                                              1st Qu.: 0.00000
##
    Median: 0.2200
                        Median: 0.0000
                                           Median :0.0000
                                                             Median: 0.00000
                              : 0.1212
##
    Mean
           : 0.8098
                                           Mean
                                                   :0.1016
                                                                     : 0.09427
                        Mean
                                                              Mean
##
    3rd Qu.: 1.2700
                        3rd Qu.: 0.0000
                                           3rd Qu.:0.0000
                                                              3rd Qu.: 0.00000
##
    Max.
            :11.1100
                               :17.1000
                                                   :5.4500
                                                                     :12.50000
                        Max.
                                           Max.
                                                              Max.
                             A.26
                                                                    A.28
##
         A.25
                                                A.27
                               : 0.0000
    Min.
            : 0.0000
                       Min.
                                           Min.
                                                   : 0.0000
                                                               Min.
                                                                      :0.0000
                                           1st Qu.: 0.0000
##
    1st Qu.: 0.0000
                        1st Qu.: 0.0000
                                                               1st Qu.:0.0000
    Median : 0.0000
                       Median : 0.0000
                                           Median : 0.0000
##
                                                               Median : 0.0000
##
    Mean
           : 0.5495
                       Mean
                              : 0.2654
                                           Mean
                                                 : 0.7673
                                                               Mean
                                                                      :0.1248
    3rd Qu.: 0.0000
                        3rd Qu.: 0.0000
                                           3rd Qu.: 0.0000
                                                               3rd Qu.:0.0000
    Max.
            :20.8300
                               :16.6600
                                           Max.
                                                  :33.3300
                                                                      :9.0900
##
                        Max.
                                                               Max.
```

```
##
         A.29
                            A.30
                                             A.31
                                                                 A.32
          : 0.00000
                              :0.0000
                                              : 0.00000
                                                                   :0.00000
##
   Min.
                                                            Min.
                       Min.
                                        Min.
    1st Qu.: 0.00000
                       1st Qu.:0.0000
                                        1st Qu.: 0.00000
                                                            1st Qu.:0.00000
   Median : 0.00000
                       Median :0.0000
                                        Median : 0.00000
                                                            Median :0.00000
##
   Mean : 0.09892
                       Mean :0.1029
                                        Mean : 0.06475
                                                            Mean :0.04705
##
    3rd Qu.: 0.00000
                       3rd Qu.:0.0000
                                        3rd Qu.: 0.00000
                                                            3rd Qu.:0.00000
          :14.28000
                              :5.8800
                                              :12.50000
                                                            Max.
                                                                  :4.76000
   Max.
                       Max.
                                        Max.
         A.33
                                              A.35
                                                                 A.36
##
                            A.34
##
   Min.
          : 0.00000
                       Min.
                              :0.00000
                                         Min.
                                                : 0.0000
                                                            Min.
                                                                   :0.00000
    1st Qu.: 0.00000
                       1st Qu.:0.00000
                                         1st Qu.: 0.0000
##
                                                            1st Qu.:0.00000
   Median: 0.00000
                       Median :0.00000
                                         Median: 0.0000
                                                            Median :0.00000
                       Mean
   Mean : 0.09723
                              :0.04784
                                         Mean : 0.1054
                                                            Mean
                                                                 :0.09748
##
##
    3rd Qu.: 0.00000
                       3rd Qu.:0.00000
                                         3rd Qu.: 0.0000
                                                            3rd Qu.:0.00000
          :18.18000
                       Max.
                              :4.76000
                                                :20.0000
                                                                   :7.69000
##
   Max.
                                         Max.
                                                            Max.
##
         A.37
                         A.38
                                          A.39
                                                              A.40
##
   Min.
          :0.000
                    Min.
                           :0.0000
                                     Min.
                                            : 0.00000
                                                         Min.
                                                                :0.00000
    1st Qu.:0.000
                    1st Qu.:0.0000
                                     1st Qu.: 0.00000
                                                         1st Qu.:0.00000
##
   Median : 0.000
                    Median : 0.0000
                                     Median: 0.00000
                                                         Median :0.00000
   Mean :0.137
                          :0.0132
                                           : 0.07863
##
                    Mean
                                     Mean
                                                         Mean
                                                              :0.06483
##
    3rd Qu.:0.000
                    3rd Qu.:0.0000
                                     3rd Qu.: 0.00000
                                                         3rd Qu.:0.00000
          :6.890
                                            :11.11000
##
   Max
                    Max.
                           :8.3300
                                     Max.
                                                         Max.
                                                                :4.76000
##
         A.41
                           A.42
                                             A.43
                                                               A.44
           :0.00000
                      Min. : 0.0000
                                                                 : 0.0000
##
                                        Min.
                                               :0.0000
   Min.
                                                         Min.
    1st Qu.:0.00000
                      1st Qu.: 0.0000
                                        1st Qu.:0.0000
                                                          1st Qu.: 0.0000
##
   Median :0.00000
                      Median : 0.0000
                                        Median :0.0000
                                                          Median : 0.0000
##
   Mean :0.04367
                      Mean : 0.1323
                                        Mean :0.0461
                                                          Mean : 0.0792
##
    3rd Qu.:0.00000
                      3rd Qu.: 0.0000
                                        3rd Qu.:0.0000
                                                          3rd Qu.: 0.0000
                                                                :20.0000
##
    Max. :7.14000
                      Max. :14.2800
                                        Max.
                                              :3.5700
                                                          Max.
                                                                 A.48
        A.45
##
                           A.46
                                             A.47
   Min. : 0.0000
                      Min. : 0.0000
                                               :0.000000
                                                            Min. : 0.00000
                                        Min.
                      1st Qu.: 0.0000
##
    1st Qu.: 0.0000
                                        1st Qu.:0.000000
                                                            1st Qu.: 0.00000
##
   Median : 0.0000
                      Median : 0.0000
                                        Median :0.000000
                                                            Median : 0.00000
   Mean : 0.3012
                      Mean : 0.1798
                                        Mean :0.005444
                                                            Mean : 0.03187
    3rd Qu.: 0.1100
                      3rd Qu.: 0.0000
                                                            3rd Qu.: 0.00000
##
                                        3rd Qu.:0.000000
##
    Max.
         :21.4200
                      Max. :22.0500
                                        Max. :2.170000
                                                            Max. :10.00000
        A.49
                           A.50
##
                                           A.51
                                                             A.52
##
           :0.00000
                      Min.
                             :0.000
                                      Min.
                                             :0.00000
                                                         Min.
                                                              : 0.0000
##
    1st Qu.:0.00000
                      1st Qu.:0.000
                                      1st Qu.:0.00000
                                                         1st Qu.: 0.0000
   Median :0.00000
                      Median : 0.065
                                      Median :0.00000
                                                         Median : 0.0000
##
   Mean
##
         :0.03857
                                      Mean :0.01698
                                                         Mean : 0.2691
                      Mean :0.139
    3rd Qu.:0.00000
                      3rd Qu.:0.188
                                      3rd Qu.:0.00000
                                                         3rd Qu.: 0.3150
                                                                :32.4780
   Max.
          :4.38500
                      Max. :9.752
                                             :4.08100
##
                                      Max.
                                                         Max.
##
         A.53
                           A.54
                                              A.55
                                                                  A.56
##
           :0.00000
                      Min. : 0.00000
                                                                        1.00
                                         Min.
                                                    1.000
   Min.
                                                :
                                                             Min.
                                                                  :
    1st Qu.:0.00000
                      1st Qu.: 0.00000
                                         1st Qu.:
                                                    1.588
                                                             1st Qu.:
                                                                        6.00
                      Median: 0.00000
   Median :0.00000
                                         Median:
                                                    2.276
                                                             Median :
                                                                      15.00
##
                      Mean : 0.04424
##
   Mean :0.07581
                                         Mean
                                                :
                                                    5.191
                                                             Mean
                                                                   :
                                                                       52.17
                      3rd Qu.: 0.00000
                                         3rd Qu.:
##
    3rd Qu.:0.05200
                                                     3.706
                                                             3rd Qu.: 43.00
                                                            Max.
##
   Max.
          :6.00300
                      Max. :19.82900
                                         Max. :1102.500
                                                                   :9989.00
##
         A.57
                         spam
##
   Min.
                1.0
                      email:2788
          :
##
    1st Qu.:
               35.0
                      spam :1813
##
   Median:
               95.0
##
   Mean : 283.3
```

3rd Qu.: 266.0 ## Max. :15841.0

Dans le fichier **spam.txt** nous observons 4601 observations, 58 variables dont 55 float, 2 int, 1 label et 1 boolean.

4. Head

head(spamData)

```
##
                         A.5 A.6 A.7 A.8 A.9 A.10 A.11 A.12 A.13 A.14
          A.2 A.3 A.4
## 1 0.00 0.64 0.64
                      ## 2 0.21 0.28 0.50
                      0 0.14 0.28 0.21 0.07 0.00 0.94 0.21 0.79 0.65 0.21
                      0 1.23 0.19 0.19 0.12 0.64 0.25 0.38 0.45 0.12 0.00
## 3 0.06 0.00 0.71
## 4 0.00 0.00 0.00
                      0 0.63 0.00 0.31 0.63 0.31 0.63 0.31 0.31 0.31 0.00
## 5 0.00 0.00 0.00
                      0 0.63 0.00 0.31 0.63 0.31 0.63 0.31 0.31 0.31 0.00
## 6 0.00 0.00 0.00
                      0 1.85 0.00 0.00 1.85 0.00 0.00 0.00 0.00 0.00 0.00
     A.15 A.16 A.17 A.18 A.19 A.20 A.21 A.22 A.23 A.24 A.25 A.26 A.27 A.28
## 1 0.00 0.32 0.00 1.29 1.93 0.00 0.96
                                                                           0
                                            0 0.00 0.00
## 2 0.14 0.14 0.07 0.28 3.47 0.00 1.59
                                            0 0.43 0.43
                                                            0
                                                                      0
                                                                           0
                                                                 0
## 3 1.75 0.06 0.06 1.03 1.36 0.32 0.51
                                            0 1.16 0.06
                                                                      0
                                                                           0
## 4 0.00 0.31 0.00 0.00 3.18 0.00 0.31
                                            0 0.00 0.00
                                                                      0
                                                                           0
                                                            0
                                                                 0
## 5 0.00 0.31 0.00 0.00 3.18 0.00 0.31
                                            0 0.00 0.00
                                                            0
                                                                      0
                                                                           0
## 6 0.00 0.00 0.00 0.00 0.00 0.00 0.00
                                                            0
                                                                      0
                                                                           0
                                            0 0.00 0.00
                                                                 0
     A.29 A.30 A.31 A.32 A.33 A.34 A.35 A.36 A.37 A.38 A.39 A.40 A.41
                                                                        A.42
                                                                           0
## 1
        0
             0
                  0
                       0
                             0
                                  0
                                       0
                                            0 0.00
                                                      0
                                                            0 0.00
                                                                      0
## 2
        0
             0
                  0
                       0
                             0
                                  0
                                       0
                                            0 0.07
                                                      0
                                                            0 0.00
                                                                      0
                                                                           0
                                                                           0
## 3
        0
             0
                  0
                       0
                             0
                                  0
                                       0
                                            0 0.00
                                                      0
                                                            0 0.06
                                                                      0
## 4
        0
                  0
                       0
                             0
                                  0
                                            0 0.00
                                                      0
                                                            0 0.00
                                                                      0
                                                                           0
                                       0
                  0
                       0
                                            0 0.00
                                                            0 0.00
                                                                           0
## 5
        0
             0
                             0
                                  0
                                       0
                                                      0
                                                                      0
        0
                  0
                       0
                             0
                                  0
                                                      0
                                                            0 0.00
                                                                           0
## 6
             0
                                       0
                                            0 0.00
                                                                      0
     A.43
                                                                       A.55
##
         A.44 A.45 A.46
                         A.47 A.48 A.49
                                          A.50 A.51
                                                     A.52
                                                           A.53
                                                                 A.54
                                                  0 0.778 0.000 0.000 3.756
## 1 0.00
             0 0.00 0.00
                            0
                                  0 0.00 0.000
## 2 0.00
             0 0.00 0.00
                             0
                                  0 0.00 0.132
                                                  0 0.372 0.180 0.048 5.114
## 3 0.12
             0 0.06 0.06
                             0
                                  0 0.01 0.143
                                                  0 0.276 0.184 0.010 9.821
## 4 0.00
             0 0.00 0.00
                                  0 0.00 0.137
                                                  0 0.137 0.000 0.000 3.537
                             0
## 5 0.00
             0 0.00 0.00
                             0
                                  0 0.00 0.135
                                                  0 0.135 0.000 0.000 3.537
## 6 0.00
             0 0.00 0.00
                             0
                                  0 0.00 0.223
                                                  0 0.000 0.000 0.000 3.000
##
     A.56 A.57 spam
## 1
       61
           278 spam
      101 1028 spam
## 2
## 3
      485 2259 spam
       40
## 4
           191 spam
## 5
       40
           191 spam
## 6
       15
            54 spam
```

Nous observons que la variable cible est située à la derniére colonne, la numéro 58.

5. Proportions

```
Y = spamData[,ncol(spamData)]
levels(Y)

## [1] "email" "spam"

mlevels(Y)


## [1] 2

table(Y)

## Y

## email spam
## 2788 1813

plot(Y)
```



```
spamProp = table(Y)[2]/(table(Y)[1]+table(Y)[2])
print(spamProp)
```

spam ## 0.3940448

```
mailProp = 1 - spamProp
print(mailProp)
```

```
## spam
## 0.6059552
```

La proportions de spam est de 39.4% et la proportion de mail est de 60.6%.

N.B. : La commande summary nous donne un résultat plus immédiat:

```
summary(spamData$spam)

## email spam
## 2788 1813
```

Classification par SVM

6. Données d'apprentissage et de test

Nous choisissons aléatoirement 75% de nos données comme étant des données d'apprentissage, les 25% restant seront destinées à tester notre modèle.


```
#On prend al?atoirement sans remise les donn?es d'apprentissage (75%) et les donn?es de test (25%).
dtSpam = sort(sample(nrow(spamData), 0.75*nrow(spamData)))
trainSpamData75<-spamData[dtSpam,]
testSpamData25<-spamData[-dtSpam,]</pre>
```

Chargement des données.

```
Xtrain = as.matrix(trainSpamData75[,-58])
Ytrain = as.matrix(trainSpamData75[,58])
```

Calculons les matrices de covariables

```
library(corrplot)
corrplot(cor(trainSpamData75[,-58]),method="number")
```



7. Calibration C-SVM

Calibrons les données avec un noyau gaussien sur les données d'apprentissage :

```
#install.packages("kernlab")
library(kernlab)
# rbfdot Radial Basis kernel "Gaussian", polydot Polynomial kernel, vanilladot Linear kernel,tanhdot Hy
ksvmTrainSpam = ksvm(Xtrain, Ytrain, kernel="rbfdot", type="C-svc")
predictTrainSpam = predict(ksvmTrainSpam, Xtrain)
```

8. Caractéristiques de la base d'apprentissage

```
matrixConfSpam = table(predictTrainSpam, Ytrain)
print(matrixConfSpam)

## Ytrain
## predictTrainSpam email spam
## email 2057 108
## spam 50 1235
```

```
FalsePositive = matrixConfSpam[1,2] / (matrixConfSpam[1,1]+matrixConfSpam[1,2])
print(FalsePositive)
## [1] 0.04988453
FalseNegative = matrixConfSpam[2,1] / (matrixConfSpam[2,1]+matrixConfSpam[2,2])
print(FalseNegative)
```

[1] 0.03891051

On note que les résultats son trés significatif avec moins de 5% d'erreur de faux positif et prés de 4% d'erreur de faux négatif.

9. Caractéristiques de la base de test

```
Xtest = as.matrix(testSpamData25[,-58])
Ytest = as.matrix(testSpamData25[,58])
predictTestSpam = predict(ksvmTrainSpam, Xtest)
matrixConfSpamTest = table(predictTestSpam, Ytest)
print(matrixConfSpamTest)
##
                  Ytest
## predictTestSpam email spam
             email
                     648
##
                      33 421
             spam
FalsePositive = matrixConfSpamTest[1,2] / (matrixConfSpamTest[1,1]+matrixConfSpamTest[1,2])
print(FalsePositive)
## [1] 0.07030129
FalseNegative = matrixConfSpamTest[2,1] / (matrixConfSpamTest[2,1]+matrixConfSpamTest[2,2])
print(FalseNegative)
```

[1] 0.07268722

On note que les résultats son trés significatif avec 56 d'erreur de faux positif et près de 5% d'erreur de faux négatif.

10. Mesure de l'impact du choix aléatoire de la base d'apprentissage


Mesurons pour 20 itérations l'erreur du modèle.

```
getError = function(Noyau){
      # 1) Choix de la base
      dtSpam = sort(sample(nrow(spamData), 0.75*nrow(spamData)))
      trainSpamData75<-spamData[dtSpam,]</pre>
      testSpamData25<-spamData[-dtSpam,]</pre>
      # Initialisation des matrices
      Xtrain = as.matrix(trainSpamData75[,-58])
      Ytrain = as.matrix(trainSpamData75[,58])
      Xtest = as.matrix(testSpamData25[,-58])
      Ytest = as.matrix(testSpamData25[,58])
      # 2) Calibration du mod?le sur la base d'apprentissage
      ksvmTrainSpam = ksvm(Xtrain, Ytrain, kernel=Noyau, type="C-svc")
      # 3) Evaluation de l'erreur sur la base de test
      predictTestSpam = predict(ksvmTrainSpam, Xtest)
      matrixConfSpamTest = table(predictTestSpam, Ytest)
      # Retourne l'erreur
      return (as.numeric((matrixConfSpamTest[1,2]+matrixConfSpamTest[2,1]) / (matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrixConfSpamTest[1,1]+matrix
      }
error = c()
Noyau = "rbfdot"
for(k in 1:20){
      error[k] = getError(Noyau)
}
#Erreur minimum :
print(error[which.min(error)])
## [1] 0.05821025
# Erreur maximum :
print(error[which.max(error)])
## [1] 0.08427454
# Erreur moyenne :
print(mean(error))
## [1] 0.07098175
```


Sur 20 itérations, l'erreur minimum est de 5%, l'erreur maximum est de 8% et l'erreur moyenne de 7%. Affichons l'histogramme et la boite à moustache des erreurs pour le noyau gaussien.

```
hist(error, col="firebrick1")
```

Histogram of error



boxplot(error)



En conclusion, un noyau gaussien est mieux adapté.

11. Comparaison des performances des 3 noyaux

Comparons les performances des 3 noyaux gaussien, polynomial et linéaire sur 40 itérations

```
errorLinear= c()
errorPoly = c()
errorGauss = c()


for(k in 1:40){
   errorLinear[k] = getError("vanilladot")
   errorPoly[k] = getError("polydot")
   errorGauss[k] = getError("rbfdot")
}
```

```
## Setting default kernel parameters
```

```
## Setting default kernel parameters
   Setting default kernel parameters
## Setting default kernel parameters
   Setting default kernel parameters
   Setting default kernel parameters
##
   Setting default kernel parameters
##
   Setting default kernel parameters
   Setting default kernel parameters
## Setting default kernel parameters
   Setting default kernel parameters
## Setting default kernel parameters
   Setting default kernel parameters
##
   Setting default kernel parameters
##
   Setting default kernel parameters
##
   Setting default kernel parameters
## Setting default kernel parameters
## Setting default kernel parameters
##
   Setting default kernel parameters
   Setting default kernel parameters
##
   Setting default kernel parameters
   Setting default kernel parameters
##
   Setting default kernel parameters
## Setting default kernel parameters
## Setting default kernel parameters
   Setting default kernel parameters
## Setting default kernel parameters
   Setting default kernel parameters
##
   Setting default kernel parameters
   Setting default kernel parameters
##
   Setting default kernel parameters
## Setting default kernel parameters
   Setting default kernel parameters
   Setting default kernel parameters
## Setting default kernel parameters
## Setting default kernel parameters
   Setting default kernel parameters
##
   Setting default kernel parameters
   Setting default kernel parameters
## Setting default kernel parameters
   Setting default kernel parameters
## Setting default kernel parameters
   Setting default kernel parameters
##
   Setting default kernel parameters
   Setting default kernel parameters
##
   Setting default kernel parameters
## Setting default kernel parameters
## Setting default kernel parameters
## Setting default kernel parameters
## Setting default kernel parameters
## Setting default kernel parameters
## Setting default kernel parameters
```

```
## Setting default kernel parameters
## Noyau Lin?aire :
# Erreur minimum :
print(errorLinear[which.min(errorLinear)])
## [1] 0.05734144
# Erreur maximum :
print(errorLinear[which.max(errorLinear)])
## [1] 0.08774978
# Erreur moyenne :
print(mean(errorLinear))
## [1] 0.0717854
#Histogramme de l'erreur
hist(errorLinear, col="firebrick1")
```

Histogram of errorLinear



```
## Noyau Polynomiale :
#Erreur minimum :
print(errorPoly[which.min(errorPoly)])

## [1] 0.05299739

# Erreur maximum :
print(errorPoly[which.max(errorPoly)])


## [1] 0.09035621

# Erreur moyenne :
print(mean(errorPoly))

## [1] 0.06939618

#Histogramme de l'erreur
hist(errorPoly, col="firebrick1")
```

Histogram of errorPoly



```
## Noyau Gaussien :
#Erreur minimum :
print(errorGauss[which.min(errorGauss)])

## [1] 0.05734144

# Erreur maximum :
print(errorGauss[which.max(errorGauss)])


## [1] 0.07906169

# Erreur moyenne :
print(mean(errorGauss))

## [1] 0.07011295


#Histogramme de l'erreur
hist(errorGauss, col="firebrick1")
```

Histogram of errorGauss



Comparons empiriquement les erreurs des 3 noyaux:

boxplot(errorLinear, errorPoly, errorGauss)



En conclusion le noyau présentant l'erreur la plus basse est le noyau gaussien.

Application III : Modèle de régression par SVM

1. Noyau et performance de UsCrime

Procédons au chargement du fichier UsCrime.txt :

```
usCrimeData = read.table('UsCrime.txt',header=TRUE, sep=' ')
#names(usCrimeData) <- NULL # suppression des headers</pre>
```

Comparons différents modèles de régression permettant de prédire le taux de crimminalité à l'aide d'un modèle SVM.

```
# library(kernlab)
# help(ksvm)
# getErrorUsCrime = function(NoyauUs = "rbfdot"){
# # 1) Choix de la base
# dtusCrime = sort(sample(nrow(usCrimeData), 0.75*nrow(usCrimeData)))
# trainusCrimeData75<-usCrimeData[dtusCrime,]
# testusCrimeData25<-usCrimeData[-dtusCrime,]
# # Initialisation des matrices
# XtrainUsCrime = as.matrix(trainusCrimeData75[,-1])</pre>
```

```
YtrainUsCrime = as.matrix(trainusCrimeData75[,1])
#
   XtestUsCrime = as.matrix(testusCrimeData25[,-1])
   YtestUsCrime = as.matrix(testusCrimeData25[,1])
#
#
   # 2) Calibration du mod?le sur la base d'apprentissage
#
   ksumTrainUsCrime = ksum(XtrainUsCrime, YtrainUsCrime, kernel=NoyauUs, type="C-suc")
   #BUG "dependent variable has to be of factor or integer type for classification mode."
#
#
   # 3) Evaluation de l'erreur sur la base de test
#
#
   predictTestUsCrime = predict(ksvmTrainUsCrime, XtrainUsCrime)
#
   matrixConfUsCrimeTest = table(predictTestUsCrime, YtestUsCrime)
#
#
  # Retourne l'erreur
   return (as.numeric((matrixConfUsCrimeTest[1,2]+matrixConfUsCrimeTest[2,1]) / (matrixConfUsCrimeTest
#
# }
#
#
# errorusCrimeLinear= c()
# errorusCrimePoly = c()
# errorusCrimeGauss = c()
# for(k in 1:1){
  errorusCrimeLinear[k] = getErrorUsCrime("vanilladot")
  errorusCrimePoly[k] = getErrorUsCrime("polydot")
   errorusCrimeGauss[k] = getErrorUsCrime("rbfdot")
# }
# ## Noyau Lin?aire :
# # Erreur minimum :
# print(errorusCrimeLinear[which.min(errorusCrimeLinear)])
# # Erreur maximum :
# print(errorusCrimeLinear[which.max(errorusCrimeLinear)])
# # Erreur moyenne :
# print(mean(errorusCrimeLinear))
# #Histogramme de l'erreur
# hist(errorusCrimeLinear, col="firebrick1")
# ## Noyau Polynomiale :
# #Erreur minimum :
# print(errorusCrimePoly[which.min(errorusCrimePoly)])
# # Erreur maximum :
# print(errorusCrimePoly[which.max(errorusCrimePoly)])
# # Erreur moyenne :
# print(mean(errorusCrimePoly))
# #Histogramme de l'erreur
# hist(errorusCrimePoly, col="firebrick1")
# ## Noyau Gaussien :
# #Erreur minimum :
# print(errorusCrimeGauss[which.min(errorusCrimeGauss)])
# # Erreur maximum :
# print(errorusCrimeGauss[which.max(errorusCrimeGauss)])
# # Erreur moyenne :
```

```
# print(mean(errorusCrimeGauss))
# #Histogramme de l'erreur
# hist(errorusCrimeGauss, col="firebrick1")
```

Comparons empiriquement les erreurs des 3 noyaux:

```
# boxplot(errorusCrimeLinear, errorusCrimePoly, errorusCrimeGauss)
```

En conclusion le noyau gaussien présente l'erreur la plus faible. C'est donc le modèle le plus significatif.